

FDPs del simulador: decisiones y guía para el equipo

Oct 1, 2026 · @Valen

La demanda pasa a ser un supuesto (un pedido cada 2,5 min, con escenarios $\pm 30\%$); distancia y tarifa siguen saliendo del dataset limpio. Este documento junta lo decidido y qué tiene que hacer cada FDP, para avanzar en paralelo con la simulación.

Por qué cambiamos el enfoque

El dataset de Kaggle no sirve para el intervalo de arribo (TLL), pero sigue sirviendo para distancia y tarifa. No hace falta cambiar el scope del TP: solo cambia de dónde sale una FDP.

El dataset son cotizaciones, no viajes. Un script consultó las APIs de Uber y Lyft cada pocos minutos, para rutas fijas entre ~12 barrios y para cada producto. Lo confirman tres cosas que vimos:

- Hasta 203 filas comparten el mismo timestamp: son un lote de consultas, no clientes simultáneos.
- Varios días tienen casi exactamente ~20.000 filas, incluidos sábado, domingo y lunes. La demanda real no es constante.
- Hay días sin datos (05/12 al 08/12, 11/12 y 12/12) y días casi vacíos: el script estuvo apagado.

Por eso el intervalo calculado con `timestamp.diff()` mide el ritmo del script. Si lo usáramos, el simulador recibiría un pedido cada pocos segundos.

Variable	¿Sale del dataset?	Nota
Distancia	Sí	Deduplicar: las 6 filas de una consulta comparten distancia
Tarifa	Sí	Filtrar producto estándar; modelar en función de la distancia
Duración	No (nunca estuvo)	Se calcula desde la distancia sorteada y una velocidad supuesta

Variable	¿Sale del dataset?	Nota
Tiempo de búsqueda	No (nunca estuvo)	Supuesto declarado
Intervalo de arribo	No	Supuesto anclado en datos oficiales de Boston (esta propuesta)

Decisiones tomadas

Simulamos una zona chica de Boston con una sola plataforma (Lyft), y la demanda es un supuesto simple en vez de una FDP ajustada.

- **Intervalo de arribo (TLL):** exponencial con media 2,5 min ($\approx 0,4$ pedidos/min). El informe DPU se usa solo para mostrar que es un orden de magnitud razonable.
- **Escenarios:** los tres que pide el enunciado se arman variando la demanda (tabla de abajo). En cada uno se prueban varios NCH y se elige el que mejor equilibra espera, recaudación y tiempo ocioso.
- **Premisa de negocio:** no cambia; sigue siendo encontrar la cantidad óptima de choferes. Ahora la conclusión queda como cuántos choferes conviene tener según el nivel de demanda.
- **Pendiente:** confirmar con la cátedra que aceptan la demanda como supuesto, porque el enunciado pide FDPs del dataset del TP4.

Escenario	Demanda	Intervalo medio entre pedidos
Actual	Base	2,5 min
Peor	+30 %	$\approx 1,9$ min
Mejor	-30 %	$\approx 3,6$ min

Guía por FDP

Solo distancia y tarifa se ajustan con datos; las demás son supuestos o se calculan dentro del simulador.

FDP	Qué hacer	Qué evitar
Intervalo de arribo	No usar Fitter: exponencial con media 2,5 min	Calcularlo con <code>timestamp.diff()</code> del dataset
Distancia (millas)	Partir de todo Lyft, no del subconjunto filtrado para el intervalo. Deduplicar por timestamp + origen + destino. Ajustar solo <code>lognorm</code> , <code>gamma</code> , <code>weibull_min</code> , o usar la distribución empírica	<code>dgamma</code> u otras que generan negativos; corregir con <code>np.clip</code> (crea un pico falso en el mínimo)
Tarifa (USD)	Filtrar el producto estándar (<code>name == 'Lyft'</code>). Modelar tarifa = base + k × distancia + residuo	Mezclar los 6 productos y el recargo dinámico en una sola distribución
Duración (min)	Calcularla en el simulador desde la distancia sorteada: distancia / 13 mi/h × 60 + demora	Ajustarle una FDP a datos que generamos nosotros; sortearla independiente de la distancia
Tiempo de búsqueda (min)	Supuesto: gamma o lognormal con media 5 y desvío 1,5 (lo que dice el SDD)	Normal recortada en 1 (deja un pico en 1); el notebook usa desvío 2, no 1,5

Reglas para todo el notebook:

- ☐ Elegir la distribución por BIC y QQ-plot, no por el p-valor de KS: con 30.000 datos siempre da 0
- ☐ Pasarle a `Fitter` una lista cerrada de familias con soporte positivo (`distributions=[...]`)
- ☐ Leer los parámetros de `get_best()`, no copiarlos a mano (la duración hoy usa parámetros de otra corrida)
- ☐ Fijar la semilla al principio y correr el notebook de arriba hacia abajo
- ☐ Usar `.copy()` al filtrar DataFrames antes de agregar columnas
- ☐ Revisar las muestras generadas: ningún valor negativo ni absurdo

Fuente 1: volumen de viajes en Boston (DPU Massachusetts)

En 2018 empezaron en Boston unos 42,2 millones de viajes de Uber y Lyft: ≈ 115.000 por día, ≈ 80 por minuto en toda la ciudad.

- **Qué es.** La división de TNC del Departamento de Servicios Públicos de Massachusetts (DPU) publica un informe anual de viajes desde 2017.
- **Por qué es confiable.** Las empresas están obligadas por ley a reportar los viajes originados en cada ciudad, porque pagan 20 centavos por cada uno.
- **Por qué 2018.** Es el mismo año que el dataset de Kaggle (nov-dic 2018). En todo Massachusetts fueron 81,3 millones de viajes ese año.
- **Limitación.** El informe da totales anuales por ciudad, no horarios ni intervalos. Para la forma de la demanda usamos la Fuente 2.

Los informes también traen duración y distancia promedio por ciudad. Sirven para validar el supuesto de velocidad (21 km/h) que usamos en la duración: en 2022, el viaje medio iniciado en Boston duró 16,0 minutos.

Cuenta base:

$$\frac{42{,}2 \times 10^6 \text{ viajes/año}}{365 \times 1440 \text{ min/año}} \approx 80 \text{ viajes/min}$$

Referencia (opcional): cómo se derivaría la tasa desde el DPU

Los 80 viajes por minuto son de toda Boston y de todas las empresas; nuestro sistema tiene NCH choferes, así que la tasa hay que achicarla con factores declarados como supuestos.

$$\lambda_{\text{modelo}} = \lambda_{\text{Boston}} \cdot s \cdot z \cdot h$$

Factor	Qué representa	De dónde sale
λ_{Boston}	Viajes por minuto en toda la ciudad (≈ 80)	Informe DPU 2018
s	Participación de la plataforma simulada (ej. Lyft)	Supuesto; buscar una fuente de cuota de mercado

Factor	Qué representa	De dónde sale
z	Fracción de la demanda que cae en la zona modelada	Supuesto, según qué barrios simulemos
h	Ajuste por franja horaria (pico o valle frente al promedio)	Perfil horario de la Fuente 2

El intervalo medio entre arribos es $1/\lambda$ modelo. Con valores ilustrativos ($s = 0,3$; $z = 0,02$; $h = 1$), $\lambda \approx 0,48$ pedidos/min, o sea un pedido cada $\approx 2,1$ min. Eso es del mismo orden que los 2,5 min del placeholder actual.

Decidimos no calcular s y z por separado: alcanza con mostrar que 2,5 min es del mismo orden que lo que da el DPU. La incertidumbre la cubren los escenarios $\pm 30\%$.

Fuente 2 (opcional): forma y perfil horario (Nueva York y Chicago)

Boston no publica horarios de viajes, pero Nueva York y Chicago publican viajes reales de Uber y Lyft con su hora; sirven para la forma de la distribución y el perfil por hora.

Dataset	Qué trae	Para qué nos sirve	Limitación
NYC TLC – High Volume For-Hire Vehicle Trip Records	Viajes de Uber/Lyft desde feb 2019, archivos mensuales en Parquet. Según su diccionario de datos , incluye la hora del pedido	Calcular intervalos de arribo reales y verificar si se parecen a una exponencial	Otra ciudad; archivos grandes (alcanza con una muestra de un día)
Chicago Data Portal – Transportation Network Providers Trips (2018–2022)	Todos los viajes desde nov 2018, con millas y segundos de viaje	Perfil de demanda por hora; validar la relación distancia–duración del mismo período que Kaggle	Horas redondeadas a 15 min: no sirve para intervalos exactos

Chicago cubre noviembre–diciembre de 2018, igual que el dataset de Kaggle. Con sus millas y segundos podemos comprobar si la velocidad de 21 km/h es razonable.

Fuentes

- [Uber, Lyft use skyrocketing in Massachusetts – The Boston Globe](#) (informe DPU 2018: 42,2 M viajes en Boston, 81,3 M en Massachusetts)
- [2022 Rideshare Data Report – Mass.gov](#) (informes anuales del DPU; duración media en Boston)
- [New state website shares local ride-hailing data – MMA](#) (obligación de reporte y cargo de 20 centavos por viaje)
- [NYC TLC Trip Record Data](#)
- [Chicago – Transportation Network Providers Trips \(2018–2022\)](#)